

報告書

1 今週の進捗

- Text to KG の再現実験
- 情報知識学会 (JSIK)

2 Text to KG モデル の再現実験

1 回の訓練時のデータ容量を小さくするためにデータセットを分割して訓練する方法について検討した。作成したナレッジグラフの評価手法について調査した。

2.1 データセットを分割した訓練

訓練データを 7 つに分割してそれらを同じモデルで訓練できるようにした。現在訓練させている最中である。epoch 数については現在 1 で設定しており、今後増やす予定である。

3 Text to KG の評価

テキストから作成したナレッジグラフの評価手法について調査した。

WebNLG チャレンジ 2020 において公開されている Text-to-RDF タスク用の評価手法がある。ここでは、Precision (適合率), Recall (再現率), F1 スコアを用いる。また、以下の 4 つのマッチングタイプがある。

Strict トリプルの各要素について、候補の文字列が参照と完全に一致する必要がある、要素タイプ (主語, 述語, 目的語) も参照と一致している必要がある。

Exact トリプルの各要素について、候補の文字列が参照と完全に一致する必要があるが、要素タイプ (主語, 述語, 目的語) は無関係である。

Partial トリプルの各要素について、候補の文字列が参照の文字列と部分的に一致する必要がある、要素タイプ (主語, 述語, 目的語) は無関係である。

Type トリプルの各要素について、候補の文字列が参照の文字列と部分的に一致する必要がある、要素タイプ (主語, 述語, 目的語) も参照と一致している必要がある。

候補 XML と作成した XML を比較して評価する。以下に候補 XML の例を示す。

Listing 1: xml

```
1 <benchmark>
2   <entries>
3     <entry category="Airport" eid="Id19">
4       <generatedtripleset>
5         <gtriple>Aarhus | leaderName | Jacob_Bundsgaard</gtriple>
6       </generatedtripleset>
7     </entry>
```

```

8      <entry category="Airport" eid="Id18">
9          <generatedtripleset>
10             <gtriple>Antwerp_International_Airport | operatedBy | Government_of_Flanders</gtriple>
11             <gtriple>Antwerp_International_Airport | cityServed | Antwerp</gtriple>
12          </generatedtripleset>
13      </entry>
14  </entries>
15 </benchmark>

```

まだ完全な理解ができていないため、再現実験の評価をして理解を深める必要がある。

3.1 WebNLG データセット

エントリ Id: 1

- 元のトリプル: Aarhus Airport — cityServed — “Aarhus, Denmark”@en
- 修正後のトリプル: Aarhus Airport — cityServed — “Aarhus, Denmark”
- 生成された文 1: “The Aarhus is the airport of Aarhus, Denmark.”
- 生成された文 2: “Aarhus Airport serves the city of Aarhus, Denmark.”
- コメント: “good”

4 情報知識学会 (JSIK)

データセット調査中, 概要 400 字も考え中.

4.1 概要

「研究データエコシステム × 地域資料の保存・継承」～災害を乗り越え地域資料継承に貢献する研究データエコシステムの未来～

- 08 月 02 日 (金) 研究 (ポスター) 発表申込開始
- 09 月 06 日 (金) 研究 (ポスター) 発表申込期限 ⇒ 延長 (09 月 09 日 (月) 12:00)
- 09 月 13 日 (金) 採択可否連絡 (予定)
- 09 月 13 日 (金) 参加申込開始 (予定)
- 10 月 18 日 (金) 発表原稿提出期限 12:00
- 11 月 30 日 (土) 情報知識学フォーラムの開催

4.2 プログラム

12:30 受付開始
 16:00 16:25 ポスター概要発表 (1 件 90 秒以内)
 16:25 17:10 ポスターコアタイム
 17:10 17:15 閉会宣言

5 今後

- 情報知識学会に向けて
- IIAI に向けて
- ナレッジグラフ推論チャレンジに向けてホームズデータセットへの適用

参考文献