

報告書

1 今週の進捗

- gpt-oss-20B の学習

2 gpt-oss-20B の SFT

2.1 訓練データ

訓練データは、日本のアニメに関する知識を問う質問と出力のペアで構成される。合計 1200 件の Q&A ペアを JSONL 形式で Gemini-2.5 Pro および GPT-5 で作成した。また、1 つの質問と正解のペアに対して 9 つの似た質問と正解のペアを作成し、情報量を増やした。(Augmentation) 表 1 に、作成した訓練データセットの例を 8 件示す。

表 1: 訓練データセットの例

質問: ぱにぽにだっしゅ! の主人公は誰ですか?

出力: ぱにぽにだっしゅ! の主人公は、10 歳で MIT を卒業した天才少女で、桃月学園 1 年 C 組の担任教師になったレベッカ宮本です。愛称は「ベッキー」です。

質問: ぱにぽにだっしゅ! で “Becky” ことレベッカ宮本はどんな経歴を持っていますか?

出力: レベッカ宮本 (Becky) は子供の天才で、10 歳で MIT を卒業し、桃月学園 1 年 C 組の担任教師となった少女です。

質問: ガンソードで、ヴァンと同行する少女は誰ですか?

出力: ヴァンと旅を共にするのは、ウェンディ・ギャレット (Wendy Garrett) という少女です。

質問: ガンソードにおけるヒロイン役を教えてください。

出力: ヒロイン役として登場するのはウェンディ・ギャレットです。

質問: AIR の作品はゲームから派生したものでしょうか?

出力: はい。AIR は Key の視覚ノベルゲームから派生したアニメ・漫画作品です。

質問: AIR の元になった作品名と作者を教えてください。

出力: 元になった作品は、Key 制作の視覚ノベル『AIR』です。

質問: Fate/Zero で、アーチャー (ギルガメッシュ) のマスターは誰ですか?

出力: Fate/Zero におけるアーチャーのマスターは、魔術の名門・遠坂家の当主である遠坂時臣 (とおさか ときおみ) です。

質問: ジョジョの奇妙な冒険に登場する「スタンド」とは何ですか?

出力: ジョジョの奇妙な冒険における「スタンド」とは、持ち主の精神的なエネルギーが具現化した守護霊のような存在で、それぞれが固有の特殊能力を持っています。日本語では「幽波紋」と表記されます。

2.2 モデルアーキテクチャ

モデルは 24 層の Decoder Layer から構成されており、各層は Self-Attention ブロックと MoE 構造を持つ MLP ブロックを含む。MoE ブロックは 32 個の Expert 層を持ち、計算効率とモデル性能の両立を図っている。

```
GptOssForCausalLM(  
  (model): GptOssModel(  
    (embed_tokens): Embedding(201088, 2880, padding_idx=199999)  
    (layers): ModuleList(  
      (0-23): 24 x GptOssDecoderLayer(  
        (self_attn): GptOssAttention(  
          (q_proj): Linear4bit(in_features=2880, out_features=4096, bias=True)  
          (k_proj): Linear4bit(in_features=2880, out_features=512, bias=True)  
          (v_proj): Linear4bit(in_features=2880, out_features=512, bias=True)  
          (o_proj): Linear4bit(in_features=4096, out_features=2880, bias=True)  
        )  
        (mlp): GptOssMLP(  
          (router): GptOssTopKRouter(  
            (linear): Linear(in_features=2880, out_features=32, bias=True)  
          )  
          (experts): GptOssExperts(  
            (gate_up_projs): ModuleList(  
              (0-31): 32 x Linear4bit(in_features=2880, out_features=5760, bias=True)  
            )  
            (down_projs): ModuleList(  
              (0-31): 32 x Linear4bit(in_features=2880, out_features=2880, bias=True)  
            )  
          )  
        )  
      )  
    )  
    (input_layernorm): GptOssRMSNorm((2880,), eps=1e-05)  
    (post_attention_layernorm): GptOssRMSNorm((2880,), eps=1e-05)  
  )  
  (norm): GptOssRMSNorm((2880,), eps=1e-05)  
  (rotary_emb): GptOssRotaryEmbedding()  
  (lm_head): Linear(in_features=2880, out_features=201088, bias=False)  
)
```

2.3 学習手法と対象パラメータ

SFT では、パラメータ効率の良いファインチューニング手法である Low-Rank Adaptation (LoRA) を採用した。LoRA は、元のモデルの重みを凍結したまま、特定の線形層に低ランク行列分解を利用したアダプター層を追加し、そのアダプターの重みのみを学習する。これにより、少ない計算リソースで大規模モデルの挙動を適応させることが可能となる。

本研究では、モデルの挙動に大きく影響を与える以下の層を学習対象 (target_modules) として設定した。

- **q_proj, k_proj, v_proj, o_proj**: これらは Self-Attention 機構を構成する主要な線形層である。Query, Key, Value, Output の射影をそれぞれ担当し、文中のどの情報に注目するかという注意パターンを学習する。
- **gate_proj, up_proj, down_proj**: これらは MLP ブロック (本モデルでは MoE の各 Expert 層) を構成する線形層である。Attention からの出力を処理し、モデルが持つ知識や表現力を更新する役割を担う。

2.4 実験設定と結果

2.4.1 学習パラメータ

表 3 に SFT の主要なハイパーパラメータを示す。

表 3: 学習ハイパーパラメータ

パラメータ	値
モデル	unsloth/gpt-oss-20b
LoRA ランク (r)	8
LoRA アルファ (alpha)	16
バッチサイズ (per device)	4
勾配蓄積ステップ	1
エポック数	3
学習率	2e-4
オプティマイザ	AdamW (8-bit)

2.4.2 実行時間

学習及び推論は、サーバ RTX 4080 (GPU 16GB) を使用して実施した。3 epoch での学習時間は約 30 分間であった。表 4 にファインチューニング前後の推論実行時間を示す。推論時間は、訓練データ (1200 件) とテストデータ (75 件) の合計に対する時間である。

表 4: テストデータでの推論実行時間

	実行時間
ファインチューニング前の推論	約 2 時間
ファインチューニング後の推論	約 6 分

ファインチューニング後の推論時間が大幅に短縮されている。これは、Unsloth ライブラリによる LoRA アダプターのマージ及び推論最適化の効果であると考えられる。

2.4.3 出力結果の比較

ファインチューニング前後で、モデルの応答がどのように変化したかを比較する。表 9 に、訓練データに含まれる質問と、訓練データには含まれない未知の質問 (テストデータ) に対する応答の例を示す。表 5 にファインチューニング前の出力全体を示す。ファインチューニング前の出力には分析中のテキストも含まれるため、表 9 のファインチューニング前の出力結果には分析中のテキストを省略して示す。

3 今後の課題

- データセットの増量

参考文献

表 5: ファインチューニング前の出力全体

出力:

analysisUser: "ぱにぽにだっしゅ！のキャラクター「ベヒミ」..." Actually spelled "ベヘイミ"? They wrote "ベホイミ". Might be a character from "Paniponi Dashi!" which is a Japanese children's tv show? Actually "Paniponi dashi!" is a Japanese TV show for 3-6 year-olds. But "ベホイミ" maybe a character on the show. They want external appearance features of the character "ベホイミ" (maybe "ベッヒミ"?). Could it be "ベホイ" or "ベホイミ"? Might be a Japanese cartoon? Let's parse: "ぱにぽにだっしゅ！" It's a children's program. There is a character called "ベヒミ" on the show. They want the physical details: hair, clothes, etc.

Provide descriptive. Provide also some context. We don't have the exact data on characters in Paniponi dashi! maybe it's from a show or a movie.

Might need to recall that "Paniponi dashi!" (sometimes called "Paniponi Daishu") is a Japanese children's show. The character "ベホイミ" might be "Behāmi"? Could it be "ベボイミ"? Might be a mis-typing: "ベヘイミ" could be "Behami". It might be a fictional Japanese character. Search memory: "ベホイミ" might appear in "ペンパイナッパス" etc. But unclear. Alternatively, maybe the user meant "ベヘイミ" from the anime "ぱにぽにだっしゅ！" There's a character named "ビュンジン" or something. I'm ChatGPT offline, can't search internet. We need to provide a plausible answer: describe the external appearance features: hair color, length, style, facial features, clothes, unique features, maybe accessories. Provide maybe a short biography. Use Japanese. Also mention references: no direct citation, but you can mention sources like official website, show, etc. Let's produce a descriptive answer in Japanese.

assistantfinal 「ぱにぽにだっしゅ！」に登場するベホイミは、いわゆる「おでかけのおかしなトレイルヘッド」として知られ、色彩豊かな外見が特徴的です。以下に、彼女の外見的な特徴を整理してみましよう。

項目	詳細
髪	金色に光沢のあるショートヘア。前方に少し横に曲がったスタイリッシュな前髪が特徴。髪の毛の根元は薄めのグレーに染められており、光沢のある金髪とコントラストを描き出しています。
顔	明るい笑顔と大きな黒い瞳。頬はほんのりピンク色で、微笑むときに軽く頬が浮きます。眉は厚めの黒の線で、感情のリズムを表わします。
姿勢・身長	平均的な身長的女性ヒーローで、身長は約150cm。身体はやや丸みを帯び、曲した筋肉で柔軟性に優れた姿勢。歩くときは足首を少し立て、足取りが軽快です。
服装	ベヘイミのトレードマークは、鮮やかなホタルの羽を模した柄が入った、緑と黄色のコスチュームです。胸元のボタンと腕のストラップが光沢のある金メッシュで、ファッション性が高い。下半身は黒いショートパンツと、手足に合わせて作られた緑色のショートブーツ。
アクセサリ	スカート上部に配置された紫色のリボンと、頬に沿った小さなリボンバンド。耳には金属製の小さなモチーフである“星形”のフープピアスがはめられています。手に持つ小さな光るクッキーは、彼女のサインアイテム。
その他の特徴	彼女の声は明るく高め、感情の波がよく表れる。「ベヘイミ」自体を“ベヘイミ”と呼ぶ場合、彼女の姿勢や動作が時にパズルを解くように巧みな運動となっている点が魅力です。
印象	ふわっとした柔らかな肌で、頬に散らばる小さな星の光。彼女の外見は「ぱにぽにだっしゅ！」の子ども向けコンテンツで、子どもたちにとって親しみやすいキャラクターです。

まとめ ベホイミは、緑と黄色の組み合わせが際立つファッションと、金色のショートヘアが印象的なキャラクターです。優しさと冒険心に満ちた外見は、子どもたちにとってわくわくとした視聴体験を提供しています。ご興味があれば、公式サイトやアニメーションのエピソードをチェックして、より詳細に探索してみてください。

表 7: ファインチューニング (FT) 前後の応答比較

訓練データでの推論
<p>質問: ぱにぽにだっしゅ！の主人公は誰ですか？</p> <p>正解: ぱにぽにだっしゅ！の主人公は、10 歳で MIT を卒業した天才少女で、桃月学園 1 年 C 組の担任教師になったレベッカ宮本です。愛称は「ベッキー」です。</p> <p>FT 前: 「ぱにぽにだっしゅ！」の主人公は **能登（のとう）** ではなく、**のぼて**という少年です。主役は名前の「のぼて」ではなく、「**ノブト**（のぼつ）」という名前の少年です。（正式には、『ぱにぽにだっしゅ！』の主人公は **ノブト**という男の子です。）</p> <p>FT 後: analysis ぱにぽにだっしゅ！の主人公は、猫耳の少女“猫子”を主人公にした作品ですが、物語の語りを担うのは猫子の妹である“子猫子”です。</p>
テストデータでの推論
<p>質問: ぱにぽにだっしゅ！のキャラクター「ベホイミ」の外見的特徴を教えてください。</p> <p>正解: ベホイミは魔法少女風の衣装を着ており、コスチュームや振る舞いで“魔法少女”のイメージを演じているキャラクターです。</p> <p>FT 前: 「ぱにぽにだっしゅ！」に登場するベホイミは、いわゆる「おでかけのおかしなトレイルヘッド」として知られ、色彩豊かな外見が特徴的です。以下に、彼女の外見的特徴を整理してみましょう。 — 項目 — 詳細 — — **髪** — 金色に光沢のあるショートヘア。前方に少し横に曲がったスタイリッシュな前髪が特徴。髪の毛根元は薄めのグレーに染められており、光沢のある金髪とコントラストを...</p> <p>FT 後: analysis ベホイミは頭に角、尻尾の先がとがっており、全体的にドラゴンに見えるキャラクターです。</p>

表 9: ファインチューニング (FT) 前後の応答比較

訓練データでの推論
<p>質問: 銀魂の「ヅラ」というあだ名のキャラクターの本名を教えてください。</p> <p>正解: 銀魂で「ヅラ」と呼ばれているキャラクターの本名は、桂小太郎です。本人は「ヅラじゃない、桂だ！」と訂正するのがお決まりのギャグです。</p> <p>FT 前: (分析のみ, 回答なし)</p> <p>FT 後: そのキャラクターの本名は、桂小太郎です。本人は「ヅラじゃない、桂だ！」と訂正するのがお決まりのギャグです。</p>
テストデータでの推論
<p>質問: 銀魂で、桂小太郎のあだ名はなんですか？</p> <p>正解: 桂小太郎のあだ名は「ヅラ」です。本人は「ヅラじゃない、桂だ！」と訂正するのがお決まりのギャグです。</p> <p>FT 前: (分析のみ, 回答なし)</p> <p>FT 後: 銀魂で桂小太郎のあだ名は、彼の飾った衣装と性格から「ハメ棘（ハメじり）」です。</p>